

Bitácora de Desarrollo Asistido — Tarea 4.1: Skill de Auditoría de Modelos

Carlo E. Alicea Medina · MAI 540: Machine Learning · Atlantis University · 29 de septiembre de 2026

1. Qué intentaba lograr en cada paso

- **Cierre del Módulo 3.** En biopsias: matriz de confusión y precisión, exhaustividad y F1 de maligno, con una justificación clínica de la métrica. En Iris: agregar KNN y Random Forest usando la misma `evaluar_con_cv`, con el escalado dentro del flujo y `k` elegido por validación.
- **Definir y escribir la Skill.** Convertir mis errores de los Módulos 1 a 3 en criterios que puedan pasar o fallar, con evidencia citada y sin tocar el código.
- **Ejecutarla y medirla.** Usar (a) biopsias original, cuyas respuestas ya conocía, para medir la Skill y no solo para aprobarla; luego (b) Iris y (c) el tercer proyecto, dos ejecuciones sobre el mismo proyecto, un defecto inyectado y un proyecto extra.

2. Instrucciones que le di a Claude

Funcionaron: pasarle el enunciado completo de la tarea y pedirle que construyera primero una v1 y la probara contra respuestas conocidas antes de refinar. Pedirle que usara la misma partición y la misma función de evaluación para los cinco clasificadores (lo comprobó con `np.allclose → True`). Elegir que me preguntara cómo conseguir los notebooks antes de reconstruirlos, y que entregara el informe en PDF y DOCX.

No funcionaron o salieron mal: subí tres veces el notebook de biopsias creyendo que uno era el original; Claude comparó las huellas MD5, vio que los tres eran idénticos (mi versión corregida) y me avisó. Como no tenía a mano el original ni el tercer proyecto del aula, aceptamos reconstruir el original y usar un sustituto, y lo dejamos declarado en el README. La v1 de la Skill, escrita casi literal desde la tabla del enunciado ("que la métrica corresponda al costo real del error", "que ninguna columna describa algo posterior"), resultó ambigua: aprobaba métricas que nunca se imprimieron y daba veredictos distintos en dos ejecuciones.

3. Decisiones que tomó Claude por su cuenta

- **Verificaciones no pedidas:** V0 (ejecución sin errores), V2.5 (hiperparámetros elegidos por validación), V5 (reproducibilidad, `rng` global) y V6 (divisiones por cero, validación sin llamar).
- **Umbrales:** desbalance si $p_min < 0.8/K$; disparidad si la brecha supera 0.05 o el cociente es menor que 0.80 (regla de cuatro quintos), solo con $n \geq 30$. Los revisé y los acepté porque la v1 (umbral fijo de 0.40 y 0.10 sin justificar) había producido un falso positivo en Iris.
- **Formato del informe:** resumen con conteos, tabla ID/Verificación/Resultado/Evidencia, acciones ordenadas por gravedad y una sección de limitaciones; citas `celda N (id X)`, `l. L` y un script de inventario de solo lectura para que dos ejecuciones citen lo mismo.
- **Implementación:** `k` de KNN por `GridSearchCV` anidado ($k \in \{1, 3, \dots, 29\}$), Random Forest con 300 árboles, F2 además de F1 en biopsias, datos sintéticos con semilla para el sustituto, y `tools/run_nb.py` porque en su entorno no se podía instalar Jupyter.

4. Qué verifiqué y cómo

- Que las métricas de la sección 6d coinciden con la matriz: $VP = 43$, $FN = 11$, $FP = 25 \rightarrow$ precisión $43/68 = 0.632$ y exhaustividad $43/54 = 0.796$; la celda tiene un `assert`.
- Que KNN y los demás modelos usan las mismas 10 particiones (Mismas particiones que `evaluar_con_cv → True`) y que el `k` cambia entre particiones (3 a 19): evidencia de que no se fijó a mano.
- Que los conteos de PASA/FALLA/NSPD de cada informe los calculó un script y no se escribieron a mano; al hacerlo aparecieron errores en los resúmenes, que se corrigieron.

- Estabilidad: la v1 cambió V3.2 entre ejecuciones; la v2 repite los 18 veredictos y el inventario da el mismo SHA-256. **Límite:** ambas ejecuciones ocurrieron en la misma sesión; en la Tarea 4.2 las repetiré en sesiones nuevas.
- Defecto inyectado (escalado global antes de la CV en una copia de Iris): la Skill lo detectó y además reveló una omisión (k fijo rotulado "por CV"), que llevó a V2.5.

5. Resultado

Una Skill v2.1 con cinco refinamientos en commits atómicos, informes de tres proyectos más dos de prueba y los dos notebooks actualizados. Lo que más aprendí: una auditoría que "no encuentra nada" no es lo mismo que una que aprueba. La regla "sin evidencia no hay PASA" fue el cambio que más mejoró la Skill.