

Informe de la Tarea 4.1: Creación y Refinamiento de una Skill de Auditoría de Modelos

Carlo E. Alicea Medina

Maestría en Inteligencia Artificial, Atlantis University

MAI 540: Machine Learning

Prof. Kevin A. Garcia Gallardo

29 de septiembre de 2026

Informe de la Tarea 4.1: Creación y Refinamiento de una Skill de Auditoría de Modelos

Durante los Módulos 1 a 3 repetí a mano las mismas comprobaciones sobre cada modelo. En esta tarea las convertí en una Skill de Claude Code (Anthropic, 2026), `auditoria-modelos`, que audita un notebook sin modificarlo y entrega `AUDIT_REPORT_<proyecto>.md` con veredictos PASA, FALLA o NO SE PUEDE DETERMINAR (NSPD), cada uno con evidencia citada como `celda N (id X), l. L`. Antes cerré la evaluación de clasificación pendiente: en biopsias, con `class_weight="balanced"` y la misma partición, la exhaustividad de maligno sube de 0.630 a 0.796 (F1 0.654 $\rightarrow$ 0.705) con un accuracy idéntico de 0.748. En Iris, KNN (escalado dentro de un Pipeline de scikit-learn [Pedregosa et al., 2011] y k elegido por validación cruzada anidada para no sesgar la estimación [Cawley & Talbot, 2010]) obtuvo 0.960 y Random Forest 0.953, frente a 0.967 de la regresión logística.

Criterios de Verificación y su Origen

Cada criterio nació de un error concreto de un módulo anterior (Tabla 1) y se redactó como una tabla de decisión con condiciones de PASA, FALLA y NSPD. La regla central es que sin evidencia observada no hay PASA. Con desbalance se exigen métricas por clase, porque el accuracy oculta el desempeño en la clase minoritaria (Saito & Rehmsmeier, 2015). Para la disparidad elegí un umbral de 0.05 bajo la métrica global o un cociente menor que 0.80 respecto del mejor subgrupo, solo en subgrupos con $n \geq 30$. El 0.80 replica la regla de las cuatro quintas partes (Equal Employment Opportunity Commission, 1978), y el mínimo de 30 evita decidir con estimaciones inestables.

Tabla 1

Criterios de la Skill y error de un módulo anterior que los originó

Criterio	Qué debe cumplirse para PASA	Error que lo originó
V0 Ejecución	Ninguna salida es un error; si lo es, las métricas quedan NSPD	T3.1: ValueError por inf; el pipeline no llegaba a entrenar
V1 Métricas	Rango [0, 1]; coherencia con la matriz (± 0.01); con desbalance ($p_{\min} < 0.8/K$) hay métricas por clase; métrica justificada por el costo del error	T1.2: Adult Income con solo accuracy y 24 % de positivos; T3.1: dos modelos con accuracy de 0.748 y exhaustividad de maligno de 0.63 frente a 0.80

Criterio	Qué debe cumplirse para PASA	Error que lo originó
V2 Partición	División antes de todo <code>fit</code> que aprende; semillas; estratificación; misma partición; hiperparámetros elegidos por validación	T2.2: orden de imputación y escalado; T3.2: profundidad del árbol y comparación con particiones iguales
V3 Fuga	Ninguna métrica de prueba viene de un ajuste que vio esas filas; ningún predictor se conoce después del resultado	T2.1: <code>capital-gain</code> prohibida; T3.1: <code>sesiones_tratamiento_programadas</code> (accuracy 1.000)
V4 Disparidad	Métrica prioritaria por subgrupo; brecha ≤ 0.05 y cociente ≥ 0.80 ($n \geq 30$)	T1.2-T2.2: Adult tiene <code>sex</code> y <code>race</code> y nunca se midió por grupo
V5-V6 Reproducibilidad e integridad	Sin <code>rng</code> global consumido en varias cargas; divisiones protegidas contra cero; validación llamada antes del <code>fit</code>	T3.1: división entre <code>num_biopsias_previas</code> = 0; <code>validar_datos()</code> definida y nunca llamada

Nota. T = Tarea del curso. Criterios completos en `.claude/skills/auditoria-modelos/SKILL.md`.

Resultados por Proyecto

La Skill se ejecutó sobre (a) la app de biopsias original, (b) mi notebook de Iris con cinco clasificadores y (c) el tercer proyecto. Como el tercer proyecto del aula no estaba disponible, usé un sustituto de práctica: Adult Income con datos sintéticos. El original de (a) se reconstruyó desde mi versión corregida porque las copias disponibles eran la versión ya arreglada. La Tabla 2 compara la versión inicial (v1) con la refinada (v2).

Tabla 2

Qué detectó, qué omitió y qué falsos positivos emitió la Skill en cada proyecto

Proyecto	Detectó (v2)	Omitió	Falsos positivos / inestable
(a) Biopsias original	Fuga por <code>sesiones_tratamiento_programadas</code> (V3.2), división entre cero (V6.1), <code>validar_datos</code> sin llamar (V6.2), error de ejecución (V0), sin estratificar, solo accuracy, <code>rng</code> global. 9 FALLA	v1: división entre cero, validación sin llamar y <code>rng</code> global (sin criterio). v2: ninguna de las conocidas	v1: PASA en V1.1/V1.2 sin métricas impresas (celda 9 con error). v2: ninguno
(b) Iris, cinco modelos	0 FALLA; 14 PASA con evidencia (Pipeline, CV anidada, mismas particiones = True)	Ninguna conocida	v1: V1.3 (3 clases de $0.333 <$ 0.40) y V3.1 (<code>fit(X, y)</code> para el modelo final). v2: ninguno
(c) Tercer proyecto (sustituto)	Escalado antes de dividir, particiones distintas y sin semilla (0.796 frente a 0.807 al repetir), solo accuracy frente a una línea base de 0.749, brecha por sex: exhaustividad 0.302 frente a 0.485 global. 9 FALLA	v1: brecha por subgrupo (NSPD por no reproducir)	v1: V3.2 cambió de FALLA a PASA entre dos ejecuciones (<code>capital_gain</code>). v2: estable
Copia de Iris con defecto inyectado	Escalado global antes de la CV (V2.1, V3.1)	v2 sin V2.5: $k = 5$ fijado a mano con la etiqueta "k por CV"	—

Nota. Informes en auditorias/*/AUDIT_REPORT_*.md; versiones v1 en auditorias/historial_v1/.

Fallos de la Skill y Refinamientos

Medir la Skill contra respuestas conocidas mostró cuatro tipos de fallo. Primero, **veredictos sin evidencia**: la v1 aprobó métricas que nunca se imprimieron; el refinamiento 1 agregó V0 y la regla de que un PASA exige evidencia observada. Segundo, **falsos positivos** en Iris por umbrales mal definidos: el desbalance pasó a ser relativo al número de clases y V3.1 distingue las métricas de generalización del ajuste final o de visualización (refinamiento 2). Tercero, **inestabilidad**: dos ejecuciones de la v1 sobre el tercer proyecto discreparon en V3.2 porque el criterio no decía qué evidencia decide. Con un criterio temporal y NSPD para la sospecha, ambas ejecuciones de la v2 dan los mismos 18 veredictos, y el inventario de evidencia produce el mismo SHA-256 en cada corrida. Cuarto, **omisiones**: la división entre cero de (a) llevó a V5.2 y V6 (refinamiento 3), y el defecto inyectado en Iris llevó a V2.5 (refinamiento 4). Al ejecutar la Skill sobre un cuarto proyecto (mi notebook corregido) tuve que decidir fuera del archivo si una demostración rotulada "con fuga" contaba como fuga; esa aclaración se escribió en el SKILL.md (refinamiento 5). Esa misma ejecución encontró tres defectos que no había visto: partición sin estratificar, `cargar_datos()` que cambia los datos en cada llamada y ninguna métrica por subgrupo.

Cada refinamiento es un commit atómico que explica qué cambió y por qué. La principal limitación es que las ejecuciones repetidas se hicieron en la misma sesión y no con instancias independientes. Además, V3.2 sigue dependiendo del conocimiento del dominio cuando la fuga llega ya incluida en el archivo de datos (Kaufman et al., 2012).

Referencias

- Anthropic. (2026). *Extend Claude with skills* [Documentación]. Claude Code Docs.
<https://code.claude.com/docs/en/skills>
- Cawley, G. C., & Talbot, N. L. C. (2010). On over-fitting in model selection and subsequent selection bias in performance evaluation. *Journal of Machine Learning Research*, 11, 2079–2107.
- Equal Employment Opportunity Commission. (1978). *Uniform guidelines on employee selection procedures* (29 C.F.R. § 1607.4(D)).
- Kaufman, S., Rosset, S., Perlich, C., & Stitelman, O. (2012). Leakage in data mining: Formulation, detection, and avoidance. *ACM Transactions on Knowledge Discovery from Data*, 6(4), Artículo 15. <https://doi.org/10.1145/2382577.2382579>
- Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.
- Saito, T., & Rehmsmeier, M. (2015). The precision-recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets. *PLOS ONE*, 10(3), Artículo e0118432. <https://doi.org/10.1371/journal.pone.0118432>