

**Informe Técnico de la Tarea 4.2: Herramienta de Regresión Auditada para el Costo
Médico Anual**

Carlo E. Alicea Medina

Maestría en Inteligencia Artificial, Atlantis University

MAI 540: Machine Learning

Prof. Kevin A. Garcia Gallardo

29 de septiembre de 2026

Informe Técnico de la Tarea 4.2: Herramienta de Regresión Auditada para el Costo Médico Anual

Problema, Datos y Decisión que Apoya

La herramienta predice el costo médico anual de un asegurado, en dólares estadounidenses (USD), a partir de edad, sexo, índice de masa corporal (IMC), número de hijos, hábito de fumar y región. La predicción apoya la planificación de reservas y la priorización de programas preventivos; no está pensada para fijar primas individuales. Como el dataset público *Medical Cost Personal* no pudo descargarse en el entorno de trabajo, generé 1,500 registros sintéticos con semilla fija y la misma estructura. Incluyen faltantes en IMC e hijos, una columna de fuga (`monto_reembolsado_aseguradora`, prohibida en el archivo de contexto) y dos variables de subgrupo (`fumador` y `region`). Los datos se dividieron 80/20 antes de cualquier preprocesamiento. La imputación por mediana, el escalado y la codificación se ajustaron dentro de un Pipeline solo con el conjunto de entrenamiento (Pedregosa et al., 2011).

Métricas e Interpretación

Tabla 1

Desempeño de los tres modelos en el conjunto de prueba ($n = 300$), versión final

Modelo	MSE	RMSE (USD)	R ² prueba	R ² entrenamiento	Mejora RMSE
Referencia (media)	119,538,775	10,933	-0.010	0.000	—
Regresión lineal con interacciones	12,936,021	3,597	0.891	0.879	67 %
Random Forest (300 árboles, hoja mín. 5)	14,495,220	3,807	0.878	0.921	65 %

Nota. Mejora RMSE = $1 - \text{RMSE} / \text{RMSE de referencia}$. Misma partición y semilla (42) para los tres modelos.

El mejor modelo se equivoca, en promedio cuadrático, unos 3,600 USD por asegurado y año, frente a 10,933 USD de predecir siempre la media. Explica el 89 % de la variación del costo. Reportar solo una métrica engaña: un R² de 0.89 parece excelente, pero 3,600 USD equivalen a un 25 % del costo típico de un no fumador. El RMSE, sin el R², no dice cuánta variación falta por explicar (Hodson, 2022). No hay sobreajuste en la regresión lineal (R² de

0.879 en entrenamiento y 0.891 en prueba); el Random Forest muestra una brecha leve (0.921 frente a 0.878).

Análisis de Residuos




Figura 1. Residuos vs. valores predichos (izquierda) e histograma de residuos (derecha) de la regresión lineal final.

Antes de la corrección, los residuos de la regresión lineal se agrupaban por hábito de fumar: el costo de un fumador salta cuando su IMC es igual o mayor que 30, y un modelo aditivo no puede representar esa interacción. En la versión final, el residuo medio por tercil de predicción queda cerca de cero (+48, +108 y -437 USD), pero persisten dos patrones. Primero, la dispersión crece con el valor predicho (de 3,407 a 3,866 USD). Segundo, hay una cola derecha (asimetría de 1.78) formada por asegurados con costos extraordinarios que ninguna variable observada explica.

Hallazgos de la Auditoría y Corrección

La Skill de la Tarea 4.1 no sabía auditar regresión: marcó como fuera de rango un MSE legítimo y dejó sin evaluar 8 de 18 verificaciones. En un commit aparte la extendí con un modo de regresión: coherencia MSE/RMSE/R², referencia trivial, sobreajuste, residuos y disparidad del RMSE, con un umbral de 1.25 veces el RMSE global para subgrupos con $n \geq 30$. Esa versión encontró que la herramienta no medía el error por subgrupo y que el RMSE de los fumadores era 1.94 veces el global en la regresión lineal. Agregué interacciones fumador $\times$ IMC. La nueva auditoría detectó que esa primera corrección imputaba el IMC con la mediana del lote

transformado, lo que constituye una fuga desde el conjunto de prueba. Lo corregí dejando la imputación al SimpleImputer.

Tabla 2

Antes y después de las correcciones (misma partición)

Indicador	Antes	Después
RMSE regresión lineal (USD) / R^2	5,360 / 0.757	3,597 / 0.891
RMSE mejor modelo (USD)	3,892 (Random Forest)	3,597 (lineal)
RMSE fumadores / global, regresión lineal	1.94	1.33
Veredictos de la auditoría (PASA / FALLA / NSPD)	14 / 2 / 3	15 / 1 / 3
FALLA pendiente	V4.1, V4.2	V4.2 (fumadores 1.33×, northwest 1.30×)

Nota. NSPD = no se puede determinar. Informes completos en AUDIT_REPORT.md y auditoria/.

Limitaciones y Condiciones de No Uso

El modelo se entrenó con costos de 2,809 a 66,640 USD, edades de 18 a 64 años e IMC de 16 a 53; no debe extrapolarse fuera de esos rangos. El error es mayor en fumadores (RMSE 1.33 veces el global, aunque su error relativo es del 13 % frente al 23 % en no fumadores), en la región *northwest* (1.30 veces) y en los asegurados con costos extraordinarios, que el modelo subestima. La inflación médica, la prevalencia de tabaquismo y obesidad y los precios regionales cambian con el tiempo y obligan a reentrenar. La herramienta **no debe usarse** para fijar primas, negar cobertura o tomar decisiones clínicas, ni para ninguna decisión real mientras se base en datos sintéticos. Hay además dos cautelas: el uso de sexo y región puede estar restringido por ley, y el umbral de 1.25 es una decisión de diseño que debe revisarse con los usuarios del sistema (Kaufman et al., 2012).

Referencias

- Hodson, T. O. (2022). Root-mean-square error (RMSE) or mean absolute error (MAE): When to use them or not. *Geoscientific Model Development*, 15(14), 5481–5487.
<https://doi.org/10.5194/gmd-15-5481-2022>
- Kaufman, S., Rosset, S., Perlich, C., & Stitelman, O. (2012). Leakage in data mining: Formulation, detection, and avoidance. *ACM Transactions on Knowledge Discovery from Data*, 6(4), Artículo 15. <https://doi.org/10.1145/2382577.2382579>
- Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.